NLP 基础技术：词法分析（词性标注和词义标注）；句法分析（判断成分和句法结构，有完全/浅层句法分析）；语义分析；语用分析（具体运用）；篇章分析（整体理解分析）
NLP 应用技术：机器翻译，信息检索，情感分析，自动问答，自动文摘，社会计算，信息抽取，
正则表达式：[A-Z]（从 A 到 Z），[123]（匹配 1 或 2 或 3），[^a]（不是 a），[a^]（a 和^，因为只在[后有效），a|bc（替代产生式），?（上一个字符是可选的），+（出现一次或者更多次），*（出现 0 次或者更多次），.（点，匹配任意单个字符），$（在结尾匹配，加在 RE 的最后），^（在开头匹配，加载 RE 的最前）
错误的类别：假阳性（不该匹配却匹配，精确度），假阴性（该匹配却没有匹配，覆盖率）
词元（Lemma）：同一个词干（stem）和词性（part of speech），大致相同的词义
词形（Wordform）：词的表面形式（把单复数啥的变化都加上）
词型（Type）：一个单词
词例（Token）：词型在文章中的一个实例
中文分词：Baseline 方法是贪心(最长匹配)法

形态学 (Morphology)：研究单词是如何从语素构造
语素（Morpheme）：词干（Stem）和词缀（Affix）
两种广义的构造形式：①屈折（Inflectional）：不改变词类的词缀 (walk, walking) ②派生 (Derivational)：改变意思和词类（clue, clueless）
词干还原（Stemming）：只关心词干，不关心结构，常用于信息检索应用；比如 Porter Stemmer，基于规则去词缀，不保证产生真实词干，但不影响 IR。
断句（Segmenting Sentences）：用二分类器（EOS/NotEOS），基于规则或 ML 来判断句号是否为一句话的结束
最小编辑距离：在插入，删除和替代意义下的最少编辑距离；应用：评估机器翻译和语音识别的效果；命名实体（Named Entity）识别和指代（Entity Coreference）识别；解法：设 $D(i,j)$ 为 $A[1\dots i]$ 和 $B[1\dots j]$ 的最短编辑距离，目标是让 A 靠近 B。Levenshtein 插入和删除代价为 1，替换代价为 2。初始化 $D(i,0)=i, D(0,j)=j$

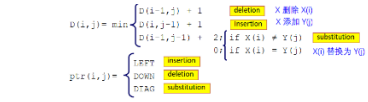

如果 Xi=Yj，则认为在这里是对齐的；为了跟踪对齐情况，仿照 LCS 维护一个箭头数组跟踪 insert(LEFT)，delete(DOWN)，subst(DIAG)；时间复杂度 O(nm)，输出 O(n+m)
带权最小编辑距离：维护单个字母 del 和 ins 权重，两字母之间 sub 权重；用于修正一些拼写错误
语言模型：$P(w_n|w_1,\dots,w_{n-1})$，但是由于数据不足，假设 Markov 性质成立；Bigram 为 Markov 链，预测用 MLE，即 P(W_i | W_{i-1})=count(Wi-1,Wi)/count(Wi-1)
Shannon 可视化方法：根据概率选<s>，然后根据给定词为条件，出现下一个词的概率选，直到选择</s>
Unigram(不用条件概率)；Bigram(用上个为条件)；Trigram；Quadrigram
封闭词汇任务和开放词汇任务（没见过的替换为<UNK>）
评价 N-gram 模型：①外在评测，Word Error Rate；②内在评测，用困惑度（Perplexity，多用于先期自测）：

$$\mathrm{PP(W)}=\mathrm{P}(w_1w_2\dots w_N)^{-1/N}$$

最小化 PP 就是最大化整个句子在模型中的出现概率；开 N 次根号用来做某种关于模型状态空间的归一化补偿；可以使用条件概率展开
问题：①过拟合，测试集和训练集相差很大则效果不好；②很多概率是 0：进行平滑：(1)Laplace 平滑，每个 Ci 都加一，则 $P_{Laplace}(w_i)=(c_i+1)/(N+V)$；

$$P^*(w_n|w_{n-1})=\frac{C(w_{n-1}w_n)+1}{C(w_{n-1})+V}$$

Bigram 如上。
加 k 法缺点是对于 0 太多的数据集，非 0 的概率会极大稀释(2)Good-Turing 平滑法，用 p0 = N1/N $c^*=(c_x+1)N_{x+1}/N_x$，其中 N_x 为出现 x 次的词的出现次数。
回退（Backoff）：如果更高阶的 Markov 没有出现，就回退到用低阶的 Markov 过程对概率进行估计
内插（Interpolation）：将不同阶输出结果线性插值，权重可以和前面的词相关；采用搜索算法找到最优权重（比如 EM 算法）
应用上我们一般用 $\exp\{\sum\log p_i\}$ 来算对应的乘法：避免下溢+加快速度
N-gram 优点：容易构建，可以使用平滑来适应新数据；缺陷：只有在测试集与训练集比较相似的情况下表现较好，只能捕捉到较短的结果；神经网络：适应能力强，但训练消耗相对较大

词类标注（POS Tagging）：①基于规则的方法②概率方法(HMM)
基准方法：无脑选最大类，查表+无脑选，RE 方法
HMM：一些状态 S，一些观测值 O，关于状态 S 的转移概率矩阵，输出概率矩阵 $B_i(k)$，即 S=i 时观测值为 k 的概率，以及初始状态 S 的概率分布
HMM Tagging：隐状态是各个 POS，输出是各个词
本身的 HMM；①（评估或计算得分问题）如何计算**给定观察序列**出现的概率？②（解码问题）给定观察序列，如何计算最优的隐状态序列？③（训练问题）如何调整模型参数来最大化某特定观察序列的概率？
定义 a 为状态转移概率，b 为观察概率。
对于①，定义 $\alpha_t(i)=P(\boldsymbol{o_1}\dots\boldsymbol{o_t}, q_t=S_i|\lambda)$，即第 t 个观察值对应的隐状态为 i 时的输出概率，则有递推关系

$$\alpha_{t+1}(j)=\left[\sum_{i=1}^{N}\alpha_t(i)a_{ij}\right]b_j(\boldsymbol{o}_{t+1}),$$

成立；$P(O|\lambda)=\sum_{i=1}^{n}\alpha_T(i)$；此方法也可以用来反向计算（Backward Algorithm）：先初始化βT = 1
对于②，使用 Viterbi 算法，定义 $\delta_t(i)=\max P[q_1\dots q_{t-1}, q_t=i, \boldsymbol{o_1}\dots\boldsymbol{o_t}|\lambda]$，即给定前 t 个观察序列下前 t-1 个隐状态最优，第 t 个状态为 i 的概率，则递推关系如下：

$$\beta_t(i)=\sum_{j=1}^{N}\boldsymbol{a_{ij}}\,b_j(\boldsymbol{o}_{t+1})\,\beta_{t+1}(j),$$

$$\delta_1(i)=\pi_i\,b_i(\boldsymbol{o}_1),$$

；同时，为了记忆最优状态，设置 $\psi_t(j)=\delta_t(j)=\max_{1\le i\le N}\left[\delta_{t-1}(i)a_{ij}\right]b_j(\boldsymbol{o}_t)$，$\mathrm{argmax}[\delta_{t-1}(i)a_{ij}]$（每个 t 都要记录 N 次，最后回溯判断）为了加速也可以进行对数化。
对于③，现在还没有全局最优解，思路大概有(1)梯度下降(2)EM 或者 Baum-Welch 迭代搜索；重估计的一种方法如下：

$$\xi_t(i,j)=\frac{P\left[q_t=S_i, q_{t+1}=S_j, \boldsymbol{O}|\lambda\right]}{P(\boldsymbol{O}|\lambda)}$$

$$\gamma_t(i)=\sum_{j=1}^{N}\xi_t(i,j)\qquad \boxed{\gamma_t(i)=P(q_t=S_i|\boldsymbol{O},\lambda)}$$

则 $\sum_{t=1}^{T-1}\xi_t(i,j)$ 表示从 Si 转移到 Sj 的期望总转移边数，$\sum_{t=1}^{T-1}\gamma_t(i)$ 表示从 Si 转移出去的总期望边数；那么，可以得到新的估计转移概率和输出概率 $\pi_i=\gamma_1(i)$，$\bar{a}_{ij}=\sum_{t=1}^{T-1}\xi_t(i,j)\,/\sum_{t=1}^{T-1}\gamma_t(i)$，$\bar{b}_j(k)=\sum_{t=1\text{ and }\boldsymbol{o}_t=v_k}^{T-1}\gamma_t(j)\,/\sum_{t=1}^{T-1}\gamma_t(j)$（$v_k$ 表示在 $\boldsymbol{O}_t$ 观察到符号 k）；<UNK>在处理中可以根据形态学猜测其词性（比如-s,-able 等）
Forward 就是加起来
重新估计转移矩阵：比如 1-1, 1-2,用有 1-1 转移的序列概率乘转移次数，1-2 转移的序列概率乘转移次数，两者归一化。

Pi: Urn 1: 0.9; Urn 2: 0.1

A

	Urn 1	Urn 2
Urn 1	0.6	0.4
Urn 2	0.3	0.7

B

	Urn 1	Urn 2
Red	0.7	0.4
Blue	0.3	0.6

Blue Blue Red

1 1 1	(0.9*0.3)*(0.6*0.3)*(0.6*0.7)=0.0204

最大熵马尔可夫链：状态是由观察值和上一个状态生成的，优化可以直接用最大似然估计，给定观察序列之后哪种隐状态的序列概率最高
评估：用人来分词，作为金标准（97%左右），和机器结果进行比较，得到 Confusion Matrix

英语核心构成：句子（表达完整的思想），子句（有一个动词），短语（一种词的聚合）
用 CFG 解析文法的问题：①一致关系（名词代词和动词的单复数形式应该对应，可以细化语法产生式，但不够简洁美观，泛化能力不够强）②次范畴化（谓语和后边的“参数”类型应该满足一些语义上的约束）；对谓语（基本是动词）进行次范畴化，约束框架称为次范畴化框架，增加语法规则③移位（倒装等特殊句式使动词和宾语的位置发生变化，用 CFG 很麻烦）
依存文法：记录词之间的论旨角色，一般是二元的；没有非终结符。
文法库的来源：①手工构造②TreeBanks，根据 POS 过的句子自动生成文法，自动解析，手工修正。
解析文法：DP 方案，有效存储二义句子；CKY 自底向上 O(n^3)，Earley 自顶向下 O（n^3）
CKY：文法全部写为 Chomsky 范式(A->BC 或 A->w)；索引 0,1,…,n 分别代表第一个单词前，第二个，第 n 个单词后；CKY 表格中填写可能的非终结符，计算 table[i,j] 时穷举从 i+1 到 j-1 这些可能分隔，并且检测其是否是有效的 Chomsky 范式；不是 Chomsky 范式的文法可以重写成 Chomsky 的。
缺陷：可能产生一些无关的成分
Partial Parsing:只处理大的组块（chunk）在哪；基于规则的部分 Parsing：去掉规则集中的递归元素（变成正则文法）；基于 ML 的 Chunking：一个序列分类任务，其把词分为三类“开始，内部和外部”，外部表

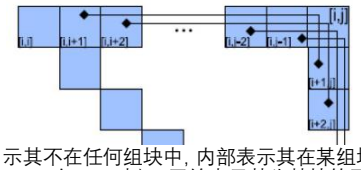

示其不在任何组块中，内部表示其在某组块中（比如 I_NP 在 NP 中），开始表示其为某块的开始（比如 B_NP）

概率 CFG：给文法规则都赋一个概率，用来解决二义性，同时模仿人类解析语言的过程；非二义的情况下就是该文法的概率，二义的情况是 n 者相加；解析树的每个 NT 都放有一个概率值；注意，对 $A\to BC$ 来说概率其实是 $P(A\to BC)*P(B)*P(C)$，只是 DP 的时候 P(B)和 P(C)肯定都已经计算出来了；如果有种 B 和 C（来源于不同的分点，但是都合法）则取最大概率的那种
求 PCFG 文法概率：用 Treebank 里面的数据进行统计）

$$P(\alpha\to\beta|\alpha)=\frac{\mathrm{Count}(\alpha\to\beta)}{\sum_\gamma\mathrm{Count}(\alpha\to\gamma)}=\frac{\mathrm{Count}(\alpha\to\beta)}{\mathrm{Count}(\alpha)}$$

或者按确定性语法进行 Parse 后进行重新估计得出概率。由此可以有改进的 maxprob CKY。
PCFG 的问题：没有考虑到推导环境的上下文（只基于很小的上下文得到一个概率），导致最优推导和 TreeBank 中的实际推导存在很大差异
解决方案：①父节点标注，将非终结符一分为 n，每个都标上其父节点的信息（$NP\to NP_{Subject}$），但是增加了语法复杂性，并且需要更多数据②中心词（NP 的中心词是名词，VP 的中心词是动词，PP 的中心词是介词），现在文法符号变成类似 VP(中心词)；由于句子太少，规则不变，PCFG 的概率变成类似 P(r|VP^dumped) = Count(这个规则用在 dump 上)/Count(dump 作为中心词出现次数)；这其实是一种次范畴化；同时，应该加入一种优先级，描述中心词和上层文法之间的选择亲和性。
Parser 评估：采用构成评估（Constituent-level Evaluation），分为覆盖率（Recall，你的解析结果中正确【即有相同节点标签和正确分点的节点】的节点数/treebank 中的相应 constitent 节点数）和精准度（Precision，你的解析结果中正确的节点数/你的解析结果中的节点数）
Recall = 2/5; Precision = 2/4;
交叉括号（Cross Brackets）：treebank has ((X Y) Z) and candidate has (X (Y Z)) 的情形；这个应该作为客观的函数来最小化

Candidate	gold
X:a	X:a
Y:b	Z:b
Z:cd	V:cd
--	Y:bcd
W:abcd	W:abcd

上述方法的缺点：会更偏向“安全的，浅的解析”；部分错误可能不停向上传播，导致很多交叉括号的情况；将所有节点一视同仁，而不是更关注核心的语义关系

四种向量语义模型：①稀疏向量表示(1)以互信息（Mutual-information）为权重的单词关联矩阵②稠密向量表示(1)奇异值分解和潜在语义分析（Latent Semantic Analysis）(2)各种神经网络模型（Skip-grams, CBOW）(3)Brown clusters
词项-文档矩阵（Term-Document Matrix），tf_{t,d}表示词 t 在 d 文档中出现的次数；两列相近则两个文档相近；两个行相近则两个词相近。
词-词（word-word）矩阵：又叫词-上下文（word-context）矩阵，a_ij 表示在每次单词 i 的±7（或者别的数）的范围内出现单词 j 的次数之和；矩阵会比较稀疏，并且窗口大小和目标有关（窗口越小语法信息越多，窗口越大语义信息越多）
两个单词间的两种互相关（co-occurrence）：①一阶互相关(syntagmatic 组合)，这些词基本都靠在一起，比如 wrote 和 book ②二阶互相关（paradigmatic 聚合），这些词的邻居相近，比如 wrote 和 said
直接计数（raw counts）的问题：直接用原始词频考察词-词相关性会有很大偏差，比如“the”和“of”一起出现的频率非常高，但是词义不一定是最贴近的；为了修正，用 PPMI（点间互信息，Positive Pointwise Mutual Information）来进行修正：PPMI(X,Y)= ____；f_ij 定义为 w_i 出现在以 c_j 为上下文的中心词当中的频数，则 p_ij, p_(i*)和 p_(*j)均容易求得。
PMI 会向出现较少的事件倾斜，解决方法：①给稀有事件更高概率：____，其中 ____,α 为一个预先给定的值（如 0.75），此方法可以平滑较大和较小的概率②用加一平滑法（差不多）
相似性度量：采用向量夹角来归一化内积；

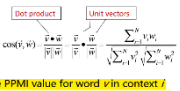

v_i is the PPMI value for word v in context i
w_i is the PPMI value for word w in context i

Vi 和 Wi 分别是 v 和 w 在上下文 i 的 PPMI 值；因为 PPMI 非负，故 cos 值在 0-1 之间

其它定义上下文的方法：通过语法环境，比如一个名词可以被那些形容词修饰，或者做哪些动词的宾语；于是，一个向量用 Relation*|V| 个关系进行修饰，比如“subject-of, absorb”这种；另一种方法是将上下文定义成“counts of words that occur in one of R Dependencies“，而不是直接用滑动窗口，比如”M(“cell”,”absorb”) = count(subj(cell,absorb)) + count(obj(cell,absorb)) + count(pobj(cell,absorb)), etc.“
PPMI 的替代指标：tf-idf（term-frequency 词的频率和 inverse document frequency），其中 df_i 表示 number of documents with word i, N 是文档的总数；则 成立。
PPMI 方法本身构造的是稀疏向量
稠密向量的优势：稠密向量更容易捕获“同义“
构造稀疏向量的方法：(1)SVD，PCA，成分分析；压缩后的词项-文档矩阵可以作为一种潜在语义分析，而 PPMI Word-Word 矩阵的 SVD 可以生成词嵌入向量(2)Skip-grams, CBOW：在猜测词的过程中产生词向量，通过训练一个神经网络来猜测临近词的意思，优势是比 SVD 快很多倍，并且可以调 word2vec 包；
Skip-grams 预测临近的 2C 个词：（因为训练目标是重建损失最小，输出向量在训练完成时会基本等于输入向量，则输出也是近似 One-hot 的）

训练目标是让重建旁边词的损失最小（用自己这个词取猜旁边的词=skipgram），同时让输出更不像随机选择的 k 个单词；Skipgram 可以证明和 PMI 有关
(3)Brown clusters：一种根据词的前后的词的聚合进行聚类的算法；一开始每个词都在一个等价类中，然后让相似的上下文的词进行 cluster，这个 cluster 操作可以看成一种二元操作，其可以生成一个二叉树，这个二叉树按编号读出来就是其词向量；相似的词其向量的距离也比较近。
Lexical Semantics (词汇语义学)
Word sense（词义）
-Homonyms (同形/同音异义词)；Polysemy (多义关系)
WordNet
是一个反应词汇之间关系的数据库，和传统词典不同：Meaning-based 遍历；结构：语义关系+同义词集
语义关系：词之间关系，概念之间关系
同义词集: 同义词是最重要的关系, wordnet 中的关系是建立在同义词集之间的，同义词是概念的例示
Super sense 可以作为词义的粗粒度表示
动词的同义词集：使用方式词连接；支持继承；时序关系更重要
形容词的同义词集：1. 描述类 2. 关系类 3. 有情感色彩类
Wordnet 可以看作一个稀疏数据库，是单词和同义词集之间的真值表（属于为 1，不属于为 0）
Wordnet 可以被 POS 限制，分为 Paradigmatic (组合) relations (within POS) 和 syntagmatic（聚合）relations (across POS)；主要有 4 类彼此未连接的 wordnet：动词、名词、形容词、副词
Wordnet 存在的问题：1. 关系未加权 2. 非常稀疏 3. 关系可能不直接 4. 未实现相互唤起 5. Types 和 roles 未分离
Wordnet 是一种词汇上的本体论
Word Similarity
同义是一种严格的 0/1 关系，而相似性是两个单词的某个语义相似即可，更宽松；相似性和关联性不同
基于词库的相似性判断
1. Path-based 相似性
c1, c2 是两个含义节点
Pathlen(c1, c2) = 1 + edges(c1 to c2)
Simpath(c1, c2) = 1/Pathlen(c1, c2)
Wordsim(w1, w2) = 两个词最相近的两个含义的 simpath
问题：每条边的权重一样，层次越高越抽象；我们希望：每条边权重相互独立，只通过抽象节点连接的相似性较低
2. Information Content similarity
P(c) 是在语料中随机抽取一个词，属于 concept c 的概率，特别地 P(root) = 1
Self-information: I(w) = -log2 P(w) 表明我们从事件发送得到信息量的多少
Information Content = -ln P(c)
最小公共包含：LCS(c1, c2) = 同时包含 c1, c2 的最低层的节点
Sim_resnik(c1, c2) = -ln P(LCS(c1, c2))
Sim_lin(c1, c2) = 2ln P(LCS(c1, c2))/(ln P(c1) + ln P(c2))
分布式相似性判断
Inside words
词语本身语义，使用“主题”表达，加入限制？ 局限性：语言太灵活了。
在特定领域（e.g. 生物）使用 wordnet 效果更好。
语义消歧（Word Sense Disambiguation）
对特定词语集合的 WSD 任务：可以使用机器学习训练分类器
适用于所有词语的任务：数据量太大，关系稀疏，不能使用针对特定词语集合的分类器
监督学习：
标签集（每个词语所有可能的含义）、训练语料（带标注）
特征提取：搭配（考虑位置，待分类词左右加减 window size 出现的词一起构成向量），词袋（不考虑位置，先构建一个可能出现的词的集合，在待分类词左右加减 window size 的窗口内统计有无出现预定集合内的词，出现处记 1，否则为 0）
分类器：可以使用朴素贝叶斯+平滑、基于规则的决策
对测试排序：可以使用 P(sense 1| feature)/P(sense 2 | feature) 来评估两种意思之间的区分程度
内在评价标准：准确率和验证集
Baseline：1. 使用最常出现的意思，人类准确率 80%；2. Lesk 算法：选择和词典中 gross 和例句重合最多的意思，给词语加权 idf_i = log(N/df_i) N 为文章总数，df_i 为单词 I 在几篇文章中出现过（在越少文章中出现说明越重要，否则不那么重要），评分变成加权和
图的观点：选取最中心的意义
半监督学习：半监督学习需要大量人工标注的数据，使用 bootstrapping 解决：
使用已知的固定搭配；或者含义基本完全一致的一篇语料作为种子，使用种子训练的分类器对所有样本进行分类，将结果可信度较高的添加到种子集合中，重复步骤
问题：可能需要对每个歧义词训练一个分类器，需要选择合适的训练集合
组合语义学（Compositional Semantics）
不需要准确知道每个词语含义，只需大致知道整体意思
1. 使用一阶逻辑，根据语法分析建立逻辑表达式，注意量词顺序
2. 使用信息抽取
信息抽取
命名实体识别（NER）
基于规则
人工构造正则表达式，或者词出现的语法规则
基于机器学习
对文本进行编码 — 人工标注训练数据 – 特征提取 – 训练分类器（抽取 substring）
IOB 编码：对于 N 类需要 2*N + 1 个标签，对于每一类：有 B-类别 表示属于某一类实体的开始，I-类别 表示实体的继续，O 表示不属于任何类
特征选择：1. word shape：将单词的长度、大小写等特征进行区分性映射
序列模型：1. MEMM（最大熵马尔科夫模型）基于当前信息和之前的决策进行决策 2. Conditional Random Fields (CRFS)：全序列条件决策模型，非局部条件决策；训练较慢，但能避免局部偏差
评价：准确率、召回率、F1
关系发现和关系分类
Tuple(a, b) 存放 a, b 之间的关系
1. 首先判断是否存在关系 2. 对关系进行分类
原因：在训练时通过第一步能过滤掉大多数词语对；不同任务可以选择不同特征集
特征：1. 命名实体本身的特征（类型、首字母等）2. 命名实体周围词语的特征（window size 内的词语） 3. 命名实体所在的语法环境（产生式、依赖式等）
半监督 bootstrapping：从已知有关系的实体出发，在语料中提取更多关系特征，再利用这些关系特征得到更多实体之间的关系，之后重复操作
模板填充
Cascades of transducers
Machine Learning：1. One seq classifier per slot 2. One big sequence classifier
问题：跟语言相关、需要特定领域知识
信息抽取的准确率不高：错误会传递（错误的命名实体识别产生错误的关系）
生物信息抽取
特定领域问题：语料充足，主要研究问题是 NER 和（相互反应）关系分析。
问答(QA)
类型：在一段材料中寻找答案；关系数据库的接口；交互式问答
主要步骤：问题分类+关键词提取 -> 文章信息抽取 -> 提取回答
问题分类：决定回答类型；一般使用人为规则和机器学习
问题关键词提取：提取出若干无关联重点词
文章抽取：先选择带有所有重点词的文章，再根据得到的文章数是否达到“门限”判断限制是否需要调整，增添或者去掉若干重点词
文章排序：1. 关键词窗口中词出现的顺序与问题中一致 2. 两个关键词之间最长距离 3. 窗口中不相关词数量
潜在答案排序：可以从维基百科或者 wordnet 中收集潜在答案
问题表述可能不同，解决方案：根据重写规则重构问题（变成填空题）-> 使用搜索引擎收集答案 -> 建立 N-gram 模型（权重，改写后的问题在文章中出现的频率）-> 筛选（与问题类型匹配的得分较高）-> 合并答案
评价指标：平均排序倒数（1/(第一个正确答案的在预测出的答案集序号)）
信息检索(Information Retrieval)
基本假设：文章含义能够根据文章中出现的词（bag of words）的频率推测
倒排索引：文章 ID+文章中查询词出现的次数；stop list：去除主题无关词（of, a 等）；stemming：关注词干
特定型检索：
向量词空间：文章和查询语句被表示为向量
D = (t1, t2, ⋯, tn) 表示 n 个词语类型，每个词语类型在文章中出现的次数，可以通过点乘来判定相似性
上述方法对所有词的权重相同，考虑加权（局部权重（表达意义）和全局权重（区分性））
局部权重：词频的函数；全局权重：idf_i = log(N/df_i)
TF-IDF Weighting：由频率推导得到的权重 * 倒排索引
通过向量空间中的方向来衡量相似性和相关度（余弦相似度）
大体步骤：根据关键词找到所有相关文章 -> 将查询语句和文章编码 -> 用余弦相似度衡量相关性并排序
摘要(summarization)
单文章摘要：选取内容 -> 对抽取的句子进行排序 -> 重新组织，删除冗余信息
选取句子：TF*IDF 加权，特征选择：线索词、开头或者结尾词、句子位置、主题词频
词语链：（指代关系构成的）链的强度用长度和同义性衡量，选取强度较强的链的第一个句子
主题词：使用 log 概率并设置值域判断一个词能不能作为主题词，包含主题词较多的句子被抽出
也可以使用机器学习方法抽取。
机器翻译
1. 基于概率和规则
评价指标
1. 人为评价：忠实度、流畅度（不同人的感受和评价不同）；Kappa 系数 = k=(p(A)-p(E))/(1-p(E)) p(A) 为评价者给出一致评价的可能性，p(E) 为平均得到一致评价的可能性（比如共 5 个评分点，P(E) = 0.2）
2. 自动评价指标：给定机器翻译和人的参考翻译，要求给出两者之间的相似性
WER(Word error rate) = (替换、查找和删除操作数)/(参考长度)
BLEU(n-gram 准确率)：短句惩罚，不能连续使用相同词两次，计算公式 BLEU=min (1, (output length)/(ref length))(∏_i▒〖precision_i〗)^{1/4}
其中 i=1,2,3,4 使用代表 i-gram 的准确率（output 中的词组是否在 ref 里出现），也可以使用多个 ref 增大可信度
3. 基于统计的机器翻译
大体思路：输入 -> 翻译模型(给出候选 p(f | e)) -> 语言模型（确定翻译的合理性 p(e)）-> 解码输出(find argmax{p(e)p(f | e)})
需要从语句对齐的语料中学习如下几个概率：
1. n(x | y) 词 y 在译文中产生 x 的概率
2. p 某个单词在译文中不出现，被删除的概率
3. t 实际的翻译概率表
4. d(j | i) 原文中位置 i 的词出现在译文中位置 j 的概率
词语对齐：开始时假设所有词语的对应都是等概率的，然后观察两种语言的哪些词经常一起出现，并提升他们的概率；
EM 算法：1. 找出所有可能的以已知语言词汇为条件的未知绑定词汇的概率，并假设等可能 2. 计算可能的组合绑定情况的概率并标准化 3. 对一组绑定，寻找出现的证据，并乘响应的概率，标准化 4. 概率最大的即为需要的绑定 p(f | e)
对于给定的 f 寻找使得 p(f | e)*p(e) 最大的 e，使用动态规划求解。
Word based 翻译缺陷：对多个已知单词对应同一个未知语言的情况难以处理，于是有 phrase based 翻译：1. 先将待翻译语料划分为词组（很多可能的划分）2. 对应词组翻译 3. 解码；好处：多对多映射；减少单个词语的歧义性
换位概率 d(a_i-b_(i-1))=α^(|a_i-b_(i-1)|)，其中 a_i 是 第 i 个英语单词翻译成的目标语言后所在的位置，b_{i-1} 是第 i-1 个对应的位置
P(f | e) = 对应词组翻译概率 乘 换位概率
为了训练对应词组翻译概率需要很大的双语语料，并且做词组对齐 。词组对齐首先进行单词对齐，之后使用概率最大的单词对齐组合。解码过程同样可以使用动态规划或者 A* 搜索。
基于机器学习的翻译
RNN：直接计算 p(target | source) 概率，进行端到端训练
输入输出使用 word embedding，输出概率使用 softmax 标准化，测试时选择每次选择概率最大的单词输出
局限：1. 受限于词语库大小，希望扩大词汇范围（拷贝技巧，加入<unknow>标签） 2. 长句子翻译不理想（使用 attention）3. 有些语言比较复杂（使用字符层面翻译预测）