

Notes of Computational Method

Michael Zhu

2016.6.8

Contents

0	绪论	4
1	插值	5
1.1	Lagrange 插值	5
1.2	Newton 插值	5
1.3	Hermite 插值	6
1.4	分段插值	6
1.5	三次样条函数	7
2	数值微分和数值积分	7
2.1	数值微分	7
2.1.1	差商和数值微分	7
2.1.2	插值型数值微分	7
2.2	数值积分	8
2.2.1	插值型数值微分	8
2.2.2	Newton-Cotes 积分	8
2.3	复化数值积分	9
2.3.1	复化梯形积分	9
2.3.2	复化 Simpson 积分	9
2.3.3	Romberg 算法	10

2.4	重积分计算	10
2.4.1	复化梯形积分	10
2.5	Gauss 型积分	10
3	曲线拟合的最小二乘法	10
3.1	线性拟合与二次拟合	10
3.1.1	线性拟合	10
3.1.2	二次拟合	10
3.2	解矛盾方程组	11
4	非线性方程求根	11
4.1	二分法	11
4.2	迭代法	11
4.3	Newton 法	12
4.4	弦截法	12
4.5	方程组的 Newton 法	12
5	线性方程组-直接法	12
5.1	消元法	12
5.1.1	Gauss 消元法	12
5.1.2	列主元消元法	13
5.1.3	Gauss-Jordan 消元法	13
5.2	直接分解法	13
5.2.1	Dolittle 分解	13
5.2.2	Courant 分解	13
5.2.3	追赶法	14
6	线性方程组-迭代法	14
6.1	Jacobi 迭代	14
6.2	Gauss-Seidel 迭代	14
6.3	松弛迭代	14
6.4	逆矩阵计算	14

7	矩阵的特征值与特征向量	14
7.1	幂法	14
7.1.1	幂法的计算	14
7.1.2	幂法的规范运算	14
7.2	反幂法	15
7.3	实对称矩阵的 Jacobi 法	15
7.4	QR 方法	15
8	常微分方程数值解	15
8.1	Euler 公式	15
8.1.1	基于数值差商	15
8.1.2	基于数值积分	16
8.2	Runge-Kutta 法	16
8.3	线性多步法	16
8.4	常微分方程组的数值解法	16

0 绪论

绝对误差 $e = x^* - x$

绝对误差限 $|e| \leq \epsilon$

相对误差 $e_r = \frac{x^* - x}{x^*}$

相对误差限 $|e_r| \leq \epsilon_r$

产生误差的主要原因 原始误差, 截断误差, 舍入误差

有效位数 当 x 的误差限为某一位的半个单位, 则这一位到第一个非零位的位数称为 x 的有效位数。

向量范数 (L_p) $\|\mathbf{X}\|_p = (\sum_{i=1}^n |x_i|^p)^{1/p}, 1 \leq p \leq \infty.$

$$p = 1 \quad \|\mathbf{X}\|_1 = \sum_{i=1}^n |x_i|$$

$$p = 2 \quad \|\mathbf{X}\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2}$$

$$p = \infty \quad \|\mathbf{X}\|_\infty = \max_{1 \leq i \leq n} \{|x_i|\}$$

矩阵范数 $\|\mathbf{A}\| = \sup_{\substack{x \in \mathbf{R}^n \\ x \neq 0}} \frac{\|\mathbf{A}\mathbf{x}\|}{\|\mathbf{x}\|}$ 或 $\|\mathbf{A}\| = \sup_{\substack{x \in \mathbf{R}^n \\ \|\mathbf{x}\|=1}} \|\mathbf{A}\mathbf{x}\|$

$$p = 1 \quad \|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

$$p = \infty \quad \|\mathbf{A}\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

$$p = 2 \quad \|A\|_2 = (\rho(A^T A))^{1/2}$$

$$\text{谱半径} \quad \rho(A) = \max_i \{|\lambda_i|\}$$

$$\text{Euclid/Schur} \quad \|A\|_E = (\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2)^{1/2}$$

特征值与范数 $|\lambda| \leq \|A\|$, $\rho(A) \leq \|A\|$.

1 插值

1.1 Lagrange 插值

基函数

$$l_i(x) = \prod_{\substack{0 \leq j \leq n \\ j \neq i}} \frac{x - x_j}{x_i - x_j}$$

插值多项式

$$L_n(x) = \sum_{i=0}^n l_i(x) f(x_i)$$

误差

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^n (x - x_i), \quad \xi \in [a, b]$$

1.2 Newton 插值

差商

$$\text{一阶差商} \quad f[x_0, x_1] = \frac{f(x_1) - f(x_0)}{x_1 - x_0}$$

$$k \text{ 阶差商} \quad f[x_0, x_1, \dots, x_n] = \frac{f[x_1, x_2, \dots, x_k] - f[x_0, x_1, \dots, x_{k-1}]}{x_k - x_0}$$

差商的性质

(1)

$$f[x_0, x_1, \dots, x_n] = \sum_{i=0}^k \frac{f(x_i)}{\prod_{\substack{0 \leq j \leq n \\ j \neq i}} (x_i - x_j)}$$

(2) 差商与节点的顺序无关。

插值多项式

$$N(x) = f(x_0) + (x - x_0)f[x_0, x_1] + \dots + (x - x_0)(x - x_1) \cdots (x - x_{n-1})f[x_0, x_1, \dots, x_n]$$

$$N(x) = f(x_0) + \sum_{k=1}^n f[x_0, \dots, x_k](x - x_0) \cdots (x - x_{k-1})$$

误差

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^n (x - x_i) = f[x, x_0, \dots, x_n] \prod_{i=0}^n (x - x_i)$$

和 Lagrange 插值多项式的误差完全相等。

1.3 Hermite 插值

构造基函数

利用差商构造

1.4 分段插值

插值函数

$$p_i(x) = \frac{x - x_{i+1}}{x_i - x_{i+1}} f(x_i) + \frac{x - x_i}{x_{i+1} - x_i} f(x_{i+1}), \quad x_i \leq x \leq x_{i+1}$$

1.5 三次样条函数

2 数值微分和数值积分

2.1 数值微分

2.1.1 差商和数值微分

差商

向前差商

$$f'(x_0) \approx \frac{f(x_0 + h) - f(x_0)}{h}$$
$$R(x) = -\frac{h}{2}f''(\xi) = O(h)$$

向后差商

$$f'(x_0) \approx \frac{f(x_0) - f(x_0 - h)}{h}$$
$$R(x) = \frac{h}{2}f''(\xi) = O(h)$$

中心差商

$$f'(x_0) \approx \frac{f(x_0 + h) - f(x_0 - h)}{2h}$$
$$R(x) = -\frac{h^2}{6}f'''(\xi) = O(h^2)$$

2.1.2 插值型数值微分

$$f(x) \approx L_n(x) = \sum_{i=0}^n l_i(x)f(x_i)$$
$$f'(x) \approx L'_n(x) = \sum_{i=0}^n l'_i(x)f(x_i)$$

误差项

$$R(x) = \frac{d}{dx} \left(\frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^n (x - x_i) \right)$$

$x = x_j$

$$f'(x_j) = \sum_{i=0}^n l'_i(x_j) f(x_i)$$

$$R(x_j) = \prod_{\substack{i=0 \\ i \neq j}}^n (x_j - x_i) \frac{f^{(n+1)}(\xi)}{(n+1)!}$$

2.2 数值积分

代数精度

$$E_n(x^k) = I(x^k) - I_n(x^k) = 0, \quad k = 0, 1, \dots, m$$

而

$$E_n(x^{m+1}) \neq 0,$$

则称 $I_n(f)$ 具有 m 阶代数精度。具有 m 阶代数精度时，对于任意不高于 m 次的多项式 $f(x)$ 都有 $I(f) = I_n(f)$ 。

2.2.1 插值型数值微分

$$\int_a^b f(x) dx \approx \int_a^b L_n(x) dx = \sum_{i=0}^n \left[\int_a^b l_i(x) dx \right] f(x_i)$$

误差

$$E_n(f) = \int_a^b f[x_0, x_1, \dots, x_n, x] \prod_{i=0}^n (x - x_i) dx$$

2.2.2 Newton-Cotes 积分

取等距节点，亦即对区间做等距剖分。

n 为偶数时具有 $n+1$ 阶代数精度， n 为奇数时具有 n 阶代数精度。

梯形积分

$$T(f) = \frac{b-a}{2}[f(a) + f(b)]$$

$$E_1(x) = -\frac{f''(\eta)}{12}(b-a)^3$$

具有 1 阶代数精度。

Simpson 积分

$$S(f) = \frac{b-a}{6}[f(a) + 4f(\frac{a+b}{2}) + f(b)]$$

$$E_2(f) = -\frac{f^{(4)}(\eta)}{2880}(b-a)^5$$

具有 3 阶代数精度。

2.3 复化数值积分

2.3.1 复化梯形积分

$$T(h) = T_n(f) = h \left[\frac{1}{2}f(a) + \sum_{i=0}^{n-1} f(a+ih) + \frac{1}{2}f(b) \right]$$

截断误差

$$E_n(f) = -\frac{(b-a)^3}{12n^2}f''(\xi) \sim O(h^2)$$

2.3.2 复化 Simpson 积分

$$S_n(f) = \frac{h}{3} \left[f(a) + 4 \sum_{i=0}^{m-1} f(x_{2i+1}) + 2 \sum_{i=1}^{m-1} f(x_{2i}) + f(b) \right]$$

截断误差

$$E_n(f) = -\frac{(b-a)^5}{180n^4}f^{(4)}(\xi) \sim O(h^4)$$

2.3.3 Romberg 算法

$$R_{k,j} = R_{k,j-1} + \frac{R_{k,j-1} - R_{k-1,j-1}}{4^{j-1} - 1}$$

2.4 重积分计算

2.4.1 复化梯形积分

$$\int_a^b \int_c^d f(x,y) dx dy \approx hk \sum_i \sum_j c_{ij} f(x_i, y_j), \quad c_{ij} = \begin{cases} \frac{1}{4}, & \text{角点} \\ \frac{1}{2}, & \text{边点} \\ 1, & \text{内点} \end{cases}$$

2.5 Gauss 型积分

$2n - 1$ 阶代数精度, n 个节点的最高代数精度。

$$G_n(f) = \frac{(b-a)}{2} \sum_{i=1}^n \alpha_i^{(n)} f\left(\frac{(a+b) + (b-a)x_i^{(n)}}{2}\right)$$

3 曲线拟合的最小二乘法

3.1 线性拟合与二次拟合

3.1.1 线性拟合

$$\begin{pmatrix} m & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum x_i y_i \end{pmatrix}$$

3.1.2 二次拟合

$$\begin{pmatrix} m & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ a_2 \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum x_i y_i \\ \sum x_i^2 y_i \end{pmatrix}$$

更高次如法炮制即可。

非多项式可以做代换，但代换后不一定满足平方误差极小。

3.2 解矛盾方程组

求 $\|A\alpha - Y\|^2$ 的极小问题等价于解方程组

$$A^T A \alpha = A^T Y.$$

4 非线性方程求根

4.1 二分法

算法简单，但是有局限：只能算出其中一个、必须要求 $f(a)f(b) < 0$ 、只能计算实根。

4.2 迭代法

基本步骤

- (1) 构造等价形式 $f(x) = 0 \Leftrightarrow x = \phi(x)$
- (2) 取合适初值 x_0 构造迭代序列 $x_{k+1} = \phi(x_k)$
- (3) 若极限不存在，可以考虑更换初值或者迭代格式。

压缩映射定理 $\phi(x) \in C^1[a, b]$ 满足

$$a \leq \phi(x) \leq b, x \in [a, b]$$

及

$$\exists 0 < L < 1, \forall x \in [a, b], |\phi'(x)| \leq L,$$

则 $\phi(x)$ 不动点唯一，且对于 $x_0 \in [a, b]$ 的迭代序列有误差估计

$$|x^* - x_k| \leq \frac{L^k}{1-L} |x_1 - x_0|.$$

4.3 Newton 法

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

对于单重根一定收敛，为二阶方法。

对于 p 重根，为一阶迭代方法，但可取以下格式，则仍为二阶方法

$$x_{k+1} = x_k - p \frac{f(x_k)}{f'(x_k)}$$

4.4 弦截法

用差商代替导数

$$x_{k+1} = x_k - f(x_k) \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})}$$

为 1.618 阶迭代方法。

4.5 方程组的 Newton 法

$$\mathbf{X}_{k+1} = \mathbf{X}_k - \mathbf{J}^{-1}(\mathbf{X}_k)F(\mathbf{X}_k)$$

若

$$\|\mathbf{J}(\mathbf{X})\|_{\infty} \leq L < 1,$$

则迭代收敛。

5 线性方程组—直接法

5.1 消元法

5.1.1 Gauss 消元法

系数矩阵化为上三角，然后回代求解。

运算量为 $O(n^3)$

可行的充要条件是 A 的各阶顺序主子式不为零。
对角元很小会导致舍入误差的扩散。

5.1.2 列主元消元法

将第 k 列第 k 到 n 个元素绝对值最大的元素放在对角位置，然后进行消元。

相较于 Gauss 消元法只增加了选列主元和交换两行元素的过程。

5.1.3 Gauss-Jordan 消元法

将系数矩阵进一步化为对角矩阵。

但是化为对角阵的工作量略大于回代求解。

5.2 直接分解法

5.2.1 Doolittle 分解

L 为单位下三角阵（对角元为 1）， U 为上三角阵。

计算步骤 U 第一行， L 第一列， U 第二行， L 第二列……

5.2.2 Courant 分解

L 为下三角阵， U 为单位上三角阵。

计算步骤 L 第一列， U 第一行， L 第二列， U 第二行……

5.2.3 追赶法

6 线性方程组-迭代法

6.1 Jacobi 迭代

6.2 Gauss-Seidel 迭代

6.3 松弛迭代

6.4 逆矩阵计算

7 矩阵的特征值与特征向量

7.1 幂法

求解按模最大特征值。

7.1.1 幂法的计算

选取初值 $\mathbf{X}^{(0)}$, 构造向量序列

$$\mathbf{X}^{(k)} = \mathbf{A}\mathbf{X}^{(k-1)}$$

若相邻两个向量各个分量比趋于一个常数, 则

$$\lambda_1 \approx x_i^{(k+1)} / x_i^{(k)}, \quad \mathbf{v}_1 \approx \mathbf{X}^{(k)}$$

若奇偶序列各个分量比分别趋向于常数, 则

$$\lambda_1 \approx \sqrt{x_i^{(k+1)} / x_i^{(k-1)}}, \quad \mathbf{v}_{1,2} \approx \mathbf{X}^{(k+1)} \pm \lambda_1 \mathbf{X}^{(k)}$$

7.1.2 幂法的规范运算

避免计算溢出、归零。

$$\mathbf{Y}^{(k)} = \mathbf{X}^{(k)} / \|\mathbf{X}^{(k)}\|_\infty, \quad \mathbf{X}^{(k+1)} = \mathbf{A}\mathbf{Y}^{(k)} \quad (k = 0, 1, \dots)$$

7.2 反幂法

求解按模最小特征值。

7.3 实对称矩阵的 Jacobi 法

7.4 QR 方法

8 常微分方程数值解

基本步骤

(1) 对区间做分割

(2) 建立求格点函数的差分方程（递推关系式）：微分、积分、Taylor 展开

(3) 解差分方程，求出格点函数

8.1 Euler 公式

8.1.1 基于数值差商

向前差商

$$y_{n+1} = y_n + hf(x_n, y_n)$$

是一步显式格式。

向后差商

$$y_{n+1} = y_n + hf(x_{n+1}, y_{n+1})$$

是一步隐式格式，需要用迭代求解。

Picard 迭代格式

$$y_{n+1}^{(0)} = y_n + hf(x_n, y_n), \quad y_{n+1}^{(k+1)} = y_n + hf(x_{n+1}, y_{n+1}^{(k)})$$

中心差商

$$y_{n+1} = y_{n-1} + 2hf(x_n, y_n)$$

是二步二阶格式，因为该格式不稳定，故不采用。

8.1.2 基于数值积分

$$y(x_{n+1}) = y(x_n) + \int_{x_n}^{x_{n+1}} f(x, y) dx$$

矩形近似 可得到向前/向后差分公式。

梯形近似

$$y(x_{n+1}) = y(x_n) + \frac{h}{2}(f(x_n, y_n) + f(x_{n+1}, y_{n+1}))$$

此为隐式格式。

一般先用其他较为粗糙的显式公式预估初始值，再用隐式公式迭代一次进行修正，称为预估-校正过程。

改进后的 Euler 公式

$$y(x_{n+1}) = y(x_n) + \frac{h}{2}(f(x_n, y_n) + f(x_{n+1}, y_n + hf(x_n, y_n)))$$

8.2 Runge-Kutta 法

8.3 线性多步法

8.4 常微分方程组的数值解法